

KoBroadcastFairBench

실제 방송 데이터 Codex-assisted labeling
및 기존 SWA 모델 우수성 검증 계획

회의용 재구성본: 실제 방송 데이터 → toxic/non-toxic + taxonomy label → SWA ablation

2026년 6월 24일 · 방송 fairness 과제

오늘 결론: 데이터 labeling이 핵심 작업

올해 할 일은 **실제 한국어 방송 데이터**를 가져와서
Codex로 **toxic / non-toxic 1차 labeling**을 하고,
동시에 성별·연령·지역·국적 등 **fairness taxonomy category**로 나눈 뒤,
그 benchmark에서 **SWA 모델이 non-SWA baseline보다 더 잘한다**는 것을 보이는 것이다.

1

실제 방송 데이터

2

Codex pre-labeling

3

Human 검수/고정 test

4

SWA ablation

안전한 표현: Codex label은 gold label이 아니라 pre-label이다. 최종 benchmark test set은 human adjudication으로 고정한다.

검증 결과 요약

항목	검증 상태	발표에서의 처리
GitHub broadcast 폴더	확인 : KLUE-NER RoBERTa base/large + SWA + ensemble	legacy model/source로 사용
기존 성능 수치	확인 : KLUE-NER 평균 Entity F1 89.51, Char F1 94.00	기존 모델 안정성 근거
방송 fairness 데이터	GitHub에는 없음 : 실제 방송 데이터 labeling 필요	AI Hub/MBC 기반 KoBroadcastFairBench 구축
Codex labeling prototype	구축 : MBC 실제 방송 segment 23개 pre-label	toxic 1 / nontoxic 22, regional_bias 1
non-SWA baseline 결과	미존재 : repo 결과는 대부분 <code>_swa</code>	동일 조건 재학습 ablation 필요
AI Hub 방송 데이터	확인 : 591/463/71314가 실제 방송 대본·전사 후보	본 데이터 labeling 대상

근거: GitHub 현재 broadcast tree, kickoff/annual report 추출문, AI Hub 공개 데이터 페이지, 04_benchmark/labels prototype.

과제 요구사항에 맞춘 해석

요구사항

- 실제 분야 데이터 확보
- 테스트 데이터셋 구축 후 자체 성능 평가
- 공개 benchmark만이 아닌 실제 데이터 검증
- GitHub/MAF/정량 성과 업데이트

우리 쪽 답변

- AI Hub 방송대본/방송전사 기반 KoBroadcastFairBench
- 기존 KLUE-NER 코드를 fairness span tagging으로 전환
- base/large 각각 non-SWA vs SWA 비교
- SW 등록/특허는 benchmark/evaluation SW 중심

핵심 방어 논리: “이전 5년 성과는 KLUE-NER 기반 모델 안정화였고, 올해는 실제 방송 데이터로 검증 범위를 확장한다.”

새 workflow: Codex로 1차 label을 만든다



Codex가 하는 일

- toxic / nontoxic triage
- bias category 분류
- context type 분류
- low-confidence/human-review 표시

사람이 하는 일

- toxic/uncertain 우선 검수
- category 충돌 adjudication
- locked test set gold label 확정
- 논문/보고서용 품질 보증

핵심: synthetic data가 아니라 실제 방송 데이터에 Codex가 annotation을 붙이는 방식이다.

Label 구조: binary + taxonomy + context

축	Label	용도
Toxicity	<code>toxic</code> / <code>nontoxic</code> / <code>uncertain</code>	빠른 triage 및 binary classifier 평가
Broadcast risk	<code>acceptable</code> / <code>needs_review</code> / <code>problematic</code>	보도·비판 목적 인용과 실제 문제 발화 구분
Bias category	gender, age, disability, nationality, regional, religion, LGBTQ+, class, appearance, family	세부 fairness category 분류
Context type	explicit, implicit, overgeneralization, derogatory, humor/sarcasm, quoted/critical	단순 욕설 검출이 아닌 문맥 기반 평가
Span offset	<code>start/end/label</code>	기존 KLUE-NER/SWA token classification으로 변환

중요한 설계: 보도에서 차별 표현을 비판적으로 인용하면 `toxicity_label=toxic` 이지만 `broadcast_risk_decision=needs_review`, `context=quoted_critical_mention` 으로 분리한다.

Prototype: 실제 MBC 방송 segment에 적용



산출물	파일
Codex label JSONL	04_benchmark/labels/mbc_public_codex_toxic_taxonomy_labels_v0.jsonl
CSV summary	04_benchmark/labels/mbc_public_codex_toxic_taxonomy_summary.csv
Label prompt	09_prompts/codex_toxic_taxonomy_label_prompt_v1.md
Validator	scripts/validate_codex_toxic_taxonomy_labels.py

Raw text는 저작권상 내부 cache로만 유지하고, label artifact는 sample_id , text_sha256 , label, span offset 중심으로 저장한다.

AI Hub 본 데이터 적용 계획

1. **AI Hub 591** 방송대본을 1순위로 다운로드한다.
2. 대본을 3~15 turn 또는 paragraph segment로 자른다.
3. Codex prompt로 toxic/non-toxic + taxonomy + context + span offset을 생성한다.
4. toxic / uncertain / low-confidence 샘플을 우선 human review한다.
5. human adjudicated subset을 locked test set으로 고정한다.
6. Codex pre-label + human-corrected train/dev로 RoBERTa baseline/SWA를 학습·평가한다.

장점: 대량 실제 방송 데이터 분류는 Codex로 빠르게 처리하고, 최종 성능 주장에 필요한 test label 품질은 사람 검수로 방어한다.

기존 GitHub를 어떻게 쓸 것인가

두 모델/구조 = RoBERTa-base, RoBERTa-large. 증명 대상 = SWA 효과.

현재 GitHub의 실체

있는 것

- `main_SWA_NER.py` : token classification + SWA training
- `eval_across_architecture.py` : base/large/ensemble 평가
- `klue/roberta-base` , `klue/roberta-large`
- seed 1~8 multi-run script
- entity F1 / char F1 결과 로그

없는 것

- 방송대본 raw/label 데이터
- fairness taxonomy annotation
- non-SWA baseline 결과표
- 저장 checkpoint
- LLM rewrite 실험 코드

따라서: 기존 코드는 “완성된 방송 fairness 모델”이 아니라, **SWA ablation**을 빠르게 구현할 수 있는 **legacy NER training scaffold**로 재활용한다.

실험 가설을 명확히 정리

H1. 동일한 방송 fairness tagging 데이터, 동일 split, 동일 seed, 동일 architecture에서 **SWA fine-tuning**은 **standard fine-tuning baseline**보다 **span F1 / macro-F1 / worst-group accuracy**가 높거나 더 안정적이다.

비교에서 고정	비교에서 바꾸는 것	성공 조건
데이터 split, seed, tokenizer, epoch, LR, batch size	SWA on/off	SWA 평균 성능 ↑ 또는 분산 ↓
RoBERTa-base 내 비교	non-SWA vs SWA	base에서 SWA 효과 확인
RoBERTa-large 내 비교	non-SWA vs SWA	large에서 SWA 효과 확인

결과표는 이렇게 내면 된다

Model	Training	Span F1 ↑	Macro-F1 ↑	Worst-group Acc ↑	Gap ↓	비고
RoBERTa-base	standard FT	TBD	TBD	TBD	TBD	baseline
RoBERTa-base	SWA FT	TBD	TBD	TBD	TBD	base SWA 효과
RoBERTa-large	standard FT	TBD	TBD	TBD	TBD	baseline
RoBERTa-large	SWA FT	TBD	TBD	TBD	TBD	large SWA 효과
Ensemble	SWA base+large	TBD	TBD	TBD	TBD	optional best model

주의: 오늘 자료에는 새 benchmark 성능 숫자를 만들지 않는다. 대신 결과표 구조와 성공 조건을 확정한다.

KoBroadcastFairBench 데이터 설계

실제 방송 데이터를 기존 NER pipeline이 먹을 수 있는 tagging benchmark로 만든다.

데이터 소스 우선순위 — 업데이트

순위	소스	확인된 내용	사용 방식
1	AI Hub 71557 뉴스 대본 및 앵커 음성 데이터	뉴스 대본/앵커 음성. TL 244MB, VL 28MB. filekey 558639/558641	뉴스 방송 benchmark core
2	AI Hub 591 방송 콘텐츠 대본 요약 데이터	KBS 방송 대본, 장르 다양. 전체 압축 약 240MB	일반 방송 장르 확장
3	AI Hub 71314 방송콘텐츠 대화체 음성인식	시사/토론/토크쇼 등 장르별 라벨 zip 2~42MB	대화체·speaker subgroup 확장
4	AI Hub 558 텍스트 윤리검증 데이터	453,340문장, HATE/DISCRIMINATION/ABUSE 등 윤리 label	toxic/nontoxic prompt 보정·보조학습
pilot	MBC 공개 transcript	23개 실제 방송 segment prototype label 구축 완료	내부 demo/검증용만

현재 API key로 파일목록 조회는 성공. 다운로드 AI Hub 웹에서 각 데이터셋 승인 신청 후 가능.

Benchmark 목표 문장

KoBroadcastFairBench: 한국어 방송 대본에서 성별·연령·인종·국적·지역·종교·장애·성적지향·사회경제적 배경 등에 대한 **차별, 고정관념, 혐오 표현**을 문맥 기반으로 평가하고, 모델의 **집단별 공정성**을 측정하는 context-aware fairness benchmark.

단, 이번 과제 산출물에서는 이 목표를 기존 RoBERTa token-classification/SWA 코드와 바로 연결 가능한 span/tagging task로 먼저 구현한다.

Fairness taxonomy: 10개 범주

Bias category	방송대본에서 보는 위험
Gender Bias	성 역할 고정관념, 성별 능력/성격 일반화
Ageism	청년/노인/아동에 대한 무능력·의존성 일반화
Disability Bias	장애/질환 조롱, 비정상화, 무능력 연결
Racial/Ethnic/Nationality Bias	인종·민족·국적 기반 범죄성/위험성 귀인
Regional Bias	지역 출신 비하, 지역 혐오/조롱
Religious / LGBTQ+ / Class / Appearance / Family Structure	종교, 성적체성, 계층, 외모, 가족형태 관련 낙인·고정관념

Context label: 단순 욕설 검출이 아님

문제 표현

- Explicit Discrimination
- Implicit Stereotype
- Overgeneralization
- Derogatory Expression
- Humor/Sarcasm with Bias

정당/보도 맥락

- Non-discriminatory Context
- Quoted/Critical Mention
- 정책·통계·피해구제 보도
- 차별 발언을 비판/해설하는 인용

중요: 방송에서는 차별 발언을 “보도/비판 목적으로 인용”하는 경우가 많다. 이걸 문제 발화와 구분해야 모델이 쓸모 있다.

기존 KLUE-NER 코드에 맞춘 label 변환



Label type	예시	기존 코드 연결
Group span	B - GROUP / I - GROUP	KLUE-NER의 entity label처럼 처리
Biased expression span	B - BIAS / I - BIAS	sequeval span F1 계산 가능
Context span	B - CONTEXT / I - CONTEXT	인용/비판 맥락 구분 보조
Outside	0	기존 outside label 그대로 사용

이 설계가 가장 빠른 이유: 기존 `Dataset`, `entity\_f1\_func`, `char\_f1\_func`, SWA training loop를 거의 그대로 쓸 수 있음.

Annotation 최소 운영안

빠른 미팅 이후 1차

- AI Hub 591 샘플 300~500 segments
- 장르 균형: 시사/교양/예능/드라마
- 2명 독립 annotation + 충돌 adjudication
- dev/test split 먼저 고정

논문/SW등록까지 확장

- 1,000~2,000 segments human-labeled
- weak-label 후보를 human correction
- counterfactual pair 200개 이상
- license-safe release manifest 구축

오늘 결정: 정말 시간이 없으면 “500개 locked test + 500개 train/dev”부터 시작하고, SWA ablation이 가능한 형태로 먼저 끝낸다.

실험/처리 계획

오늘 미팅 후 바로 실행 가능한 단위로 쪼갬다.

실험 pipeline



1. **AI Hub 다운로드:** 591 우선, 가능하면 71314/463 transcript metadata 추가.
2. **Schema 통합:** script/utterance를 `sample_id, source, genre, speaker, text` 로 정규화.
3. **Annotation sheet:** taxonomy/context/span/reason fields 포함.
4. **BIO 변환:** 기존 KLUE-NER format처럼 `tokens`, `ner_tags` 생성.
5. **Ablation:** SWA flag on/off로 base/large 각 3~5 seed 평가.

Metric 설계

Metric	무엇을 증명하나	보고서 문장
Span/entity F1	문제 표현 span을 정확히 찾는가	기존 KLUE-NER 지표와 연결 가능
Char/token macro-F1	label imbalance 상황에서 label별 성능	기존 char F1 계승
Worst-group accuracy	가장 어려운 demographic category에서 무너지지 않는가	공정성 관점 핵심
Subgroup gap	성별/연령/국적/지역 등 집단별 성능 격차	평균 성능 이상의 검증
Counterfactual gap	보호속성만 바꿨을 때 판단이 흔들리는가	정책/윤리 평가에 적합
Calibration/ECE	confidence를 믿을 수 있는가	실증/시연에서 human review 연결

Baseline 구현에서 꼭 바뀌야 하는 부분

현재 `main_SWA_NER.py` 는 저장 경로가 항상 `_swa` 이고 SWA 객체를 만든다. non-SWA baseline을 공정하게 만들려면 아래 수정이 필요하다.

수정	내용	이유
<code>--use_swa</code>	True/False flag 추가	SWA 하나만 바꾸는 controlled ablation
dataset path args	<code>--data_dir kobroadcastfair</code>	KLUE 대신 방송 benchmark 로드
label list 저장	fairness BIO labels 저장	평가 재현성
result csv/json	seed/model/use_swa/metrics 기록	보고서 표 자동 생성
group metrics	metadata와 prediction join	worst-group/gap 계산

실행 일정: 빠르게 끝내는 버전

기간	산출물	담당/결정
D0	AI Hub 591 신청/다운로드 경로 확정, annotation guide 확정	오늘 미팅
D1-D2	샘플 500~1,000개 추출 + annotation sheet 배포	데이터 담당
D3-D5	1차 human label + adjudication + BIO 변환	annotator 2명
D6-D7	base/large non-SWA vs SWA 3 seeds	GPU 담당
D8	결과표/오차분석/MAF card/SW등록 초안	전체 정리

최소 성공: 500개 locked test라도 확보하고, 같은 split에서 SWA가 baseline보다 span F1 또는 worst-group metric에서 우위임을 보이면 된다.

리스크와 방어 논리

리스크	대응	미팅에서 말할 표현
AI Hub 승인 지연	MBC public transcript로 내부 pilot, 최종은 AI Hub로 교체	“실데이터 경로는 확보했고 승인 즉시 대체 가능”
SWA 성능 차이가 작음	평균뿐 아니라 seed variance, worst-group, calibration까지 보고	“SWA는 평균 성능뿐 아니라 안정성 향상으로 평가”
fairness label이 어려움	span label + context label을 분리해 ambiguity 줄임	“단순 혐오 검출이 아니라 방송심의 맥락 label”
기존 결과가 KLUE라 비판 가능	올해 benchmark를 실제 방송 데이터로 구축	“기존 모델을 실제 방송 benchmark에서 재검증”
raw data 공개 제한	code/schema/manifest/guideline 공개, raw text는 조건부 내부 보관	“라이선스 안전한 공개SW 형태로 분리”

SW등록/특허로 연결하는 포인트

SW등록 1

한국어 방송대본 공정성 벤치마크 구축·평가 SW

- AI Hub ingest
- annotation schema
- metric report
- baseline/SWA comparison

SW등록 2

방송대본 차별/고정관념 span 분석 SW

- span detection
- context-aware label
- group metric dashboard
- MAF 연결

특허는 보수적으로: 새 알고리즘을 무리하게 주장하기보다, “방송심의 taxonomy + subgroup metric + model averaging 안정화 평가 pipeline”을 조합한 시스템 청구항으로 검토.

오늘 회의에서 결정할 것

1. **데이터:** AI Hub 591을 main으로 갈지, 71314/463을 speaker subgroup용으로 추가할지.
2. **규모:** 1차 annotation을 500개로 할지 1,000개로 할지.
3. **Task:** 우선 span tagging만 할지, segment classification도 같이 할지.
4. **Baseline:** 기존 코드에 `--use_swa false` baseline을 바로 추가할지.
5. **GPU:** base/large × SWA/non-SWA × seed를 누가 언제 돌릴지.

추천 결정안: AI Hub 71557/591 + 500~1,000 segment + Codex toxic/category pre-label + base/large 각 3 seed ablation.

마지막 한 장 요약

우리가 할 일:

실제 방송대본을 가져와 Codex로 toxic/non-toxic과 세부 fairness category를 1차 labeling하고,
human 검수로 locked benchmark를 만든 뒤,

기존 RoBERTa+SWA 모델이 non-SWA baseline보다 더 잘한다는 실험표를 만든다.

데이터

AI Hub 71557/591 우선

Labeling

Codex pre-label + human 검수

모델

RoBERTa base/large

검증

non-SWA vs SWA